

РОССИЙСКАЯ ЭКОНОМИЧЕСКАЯ ШКОЛА

Итоговый Исследовательский Проект

на тему

Сравнительный бенчмарк коммерческих и open-source систем синтеза речи и
клонирования голоса на основе автоматических метрик качества

Студент:

группа ЭАД2026

Подпись

Беляков Кирилл

Фамилия, Имя, Отчество

May 31, 2026

Дата

Научный руководитель:

Dzyabura Daria

Фамилия, Имя, Отчество

Deputy Vice-Rector for Academic Affairs, Full Professor, Academic Director “Masters in Econ

Должность / Место работы

2026

Дата

Подпись

Москва 2026

Abstract

Рынок систем синтеза речи (Text-to-Speech, TTS) и клонирования голоса (voice cloning) стремительно растёт, однако перед разработчиком, выбирающим конкретное решение, встаёт практический вопрос: что в действительности отличает коммерческие облачные сервисы от моделей с публично доступными весами — и стоит ли вообще платить. Публичные сравнения качества либо ограничиваются одним аспектом восприятия, либо опираются на закрытые внутренние данные провайдеров и не учитывают ни стоимость, ни скорость генерации. В настоящей работе построен воспроизводимый бенчмарк 11 современных решений (6 коммерческих сервисов и 5 моделей с открытыми весами), оценённых по единому протоколу: одинаковые тексты, одинаковые опорные записи дикторов, одинаковый набор автоматических метрик качества, принятых в литературе, и сопоставимые измерения стоимости и скорости генерации. Основной нарратив работы заключается в следующем. Во-первых, ни в задаче TTS, ни в задаче клонирования голоса не существует единственной системы, которая бы доминировала остальные по всем измеряемым осям одновременно: для TTS Парето-оптимальное множество включает 6 решения из 9, для клонирования — 7 из 8, причём одна из open-source моделей оказывается на Парето-фронте в обеих задачах. Во-вторых, две независимые метрики естественности речи дают значительно расходящиеся ранжирования, тогда как две метрики схожести с диктором практически идентичны — это даёт практическое указание: для адекватной оценки натуральности нужно сообщать обе метрики, а для схожести достаточно одной. В-третьих, на стандартизованном тестовом корпусе картина разрыва между группами оказывается неоднородной: по разборчивости (Whisper-WER) и схожести с диктором по WavLM коммерческие сервисы статистически эквивалентны open-source в пределах методологически значимого порога; по студийной чистоте звука (NISQA на TTS) коммерческие действительно заметно лучше, а по эмбедингу диктора по ECAPA open-source модели заметно лучше; по UT-MOSv2 разница в обе стороны мала, но статистической мощности при 5–6 провайдерах на группу не хватает для уверенного вывода. Совокупный практический вывод: при дефолтных настройках провайдеров open-source решения уже сравнимы по качеству с коммерческими сервисами на ключевых для пользователя осях (разборчивость и схожесть голоса), а различия следует искать не в усреднённых метриках качества, а в осях стоимости, скорости, поддержки языков и устойчивости к специфическим доменам.

Contents

1	Введение	3
1.1	Контекст и постановка задачи	3
1.2	Объекты сравнения	3
1.3	Эмпирические данные	4
1.4	Методология оценки	4
2	Обзор литературы	5
2.1	Воспроизводимость и обоснование автоматических метрик	5
2.2	Контекст гипотезы H1: многокритериальность и отсутствие доминирующей модели	6
2.3	Контекст гипотезы H2: согласованность метрик и важность выбора эмбедингов	7
2.4	Контекст гипотезы H3: эквивалентность вместо различия	8
2.5	Пробел в литературе	9
3	Цель и вопросы работы	9
4	Автоматические метрики	10
4.1	Корпуса для оценки TTS	10
4.2	UTMOSv2 как прокси MOS	10
4.3	NISQA	11
4.4	Whisper-WER как метрика разборчивости	11
4.5	Speaker similarity	11
5	Методология	12
5.1	Дизайн эксперимента	13
5.2	Перечень моделей	14
5.3	Метрики	15
5.4	Калибровка метрик speaker similarity	15
6	Гипотезы	15
6.1	H1: отсутствие доминирующей модели	15
6.2	H2: согласованность метрик одного типа	16
6.3	H3: эквивалентность коммерческой и open-source групп	16
7	Результаты	17
7.1	Сводные ранжирования	17
7.2	Стоимость	18
7.3	Скорость генерации	18

7.4	H1: Парето-оптимальность	19
7.4.1	Анализ чувствительности Парето-фронта	19
7.5	H2: согласованность метрик	23
7.6	H3: эквивалентность commercial и OSS групп	24
8	Обсуждение	27
8.1	Что значит «нет доминирующего TTS»?	27
8.2	CosyVoice2 как универсально парето-оптимальная модель	27
8.3	Метрики качества несут разный сигнал	28
8.4	Эквивалентность лагерей: что показывает TOST	28
8.5	Стоимость как существенный фактор	29
8.6	Сильные и слабые стороны автоматических метрик	29
8.7	Сравнение с TTS Arena	29
9	Ограничения	30
10	Заключение	30

1 Введение

1.1 Контекст и постановка задачи

Качество синтетической речи приблизилось к человеческому уровню для целого ряда языков и доменов. На рынке одновременно сосуществуют два класса систем: коммерческие облачные сервисы (ElevenLabs, OpenAI TTS, Microsoft Azure Cognitive Services, Google Cloud Text-to-Speech, Typecast, Resemble AI), доступ к которым предоставляется только через платный API, и open-source модели, опубликованные вместе с обученной нейросетью (Coqui XTTSv2, F5-TTS, Alibaba CosyVoice2, FishAudio Fish-Speech S1 и S2 Pro), которые можно запускать на собственной инфраструктуре. При выборе системы для прикладной задачи разработчик сталкивается с тремя методологическими проблемами: (1) прямая оценка качества речи слушателями плохо воспроизводима между исследованиями и существенно зависит от состава пула слушателей; (2) существующие публичные сравнения, как правило, измеряют только одну ось качества, не учитывая стоимость и скорость генерации; (3) опорный набор текстов и дикторов варьируется от исследования к исследованию, что делает прямое сравнение результатов невозможным.

1.2 Объекты сравнения

Настоящая работа представляет собой **бенчмарк-исследование** готовых систем синтеза в режиме inference; разработка собственных моделей или дообучение существующих весов выходят за рамки работы. Сравнению подлежат 11 моделей, которые делятся на две выборки.

Шесть **коммерческих облачных API** с закрытыми весами: ElevenLabs (модель Multilingual v2 для TTS, Instant Voice Clone для cloning), OpenAI TTS (tts-1, голос *alloy*), Microsoft Azure Cognitive Services (Neural Voice en-US-AvaMultilingualNeural), Google Cloud Text-to-Speech (Neural2-F), Typecast (модель SSFM-v30, поддерживает только voice cloning) и Resemble AI (Rapid Voice Clone, также cloning-only).

Пять **open-source моделей** с публично доступными весами; инференс выполнялся на одной видеокарте NVIDIA RTX 4090: Coqui XTTSv2, F5-TTS [11], Alibaba CosyVoice2-0.5B [9], FishAudio Fish-Speech S1-mini и Fish-Speech S2 Pro.

Все модели запускались с параметрами по умолчанию из документации провайдера, без prompt-engineering и без тюнинга гиперпараметров. Такой подход моделирует поведение типичного разработчика, осуществляющего первичное знакомство с API. Сознательно не сравнивались разные тарифы одного провайдера (например, ElevenLabs Pro Voice Clone и Instant Voice Clone), а также проприетарные модели без публично доступного API.

1.3 Эмпирические данные

В качестве источника эталонных текстов и опорных записей использован открытый корпус LibriTTS-R [2] в варианте *test-clean*, лицензия CC BY 4.0; собственный сбор речевых данных в работе не проводился. Корпус является общепризнанным стандартом для сравнения нейронных TTS-моделей (CosyVoice2, XTTSv2, F5-TTS публикуют результаты на нём) и состоит из чистой студийной читки 39 английских дикторов с применением модели DEMUCS для шумоподавления исходного LibriTTS.

После фильтрации по доступной длительности референса (5–10 секунд) и эталонного аудио целевых утверждений (2–15 секунд) в *test-clean* остаётся 34 пригодных диктора, из которых случайным образом отобраны 20 с балансом по полу (10 мужчин и 10 женщин); для каждого диктора — по 20 текстовых утверждений (эмпирический диапазон длины текстов в выборке — 14–283 символа). Эксперимент покрывает обе задачи синтеза:

- **Text-to-Speech** (фиксированный голос провайдера) — 9 моделей дают по 400 файлов; Typecast и Resemble не поддерживают TTS-режим.
- **Voice cloning** (zero-shot, опорная запись длительностью 5–10 секунд из того же диктора, не входящая в целевые 20 утверждений) — все 11 моделей; у Resemble AI выборка сокращена до 280 файлов из-за требований к минимальной длине референса.

Итоговый объём сгенерированного корпуса — 6680 файлов.

1.4 Методология оценки

В работе применяются исключительно **автоматические метрики** качества, без привлечения слушателей. Этот выбор продиктован четырьмя аргументами: (i) воспроизводимость результатов между запусками и независимыми лабораториями, тогда как субъективные MOS-оценки варьируются на 0.2 балла и более между разными пулами слушателей [8]; (ii) масштаб эксперимента (6680 файлов), для которого получение хотя бы трёхкратного человеческого MOS требует более 24000 субъективных оценок; (iii) наличие в сообществе устоявшегося прокси — UTMOSv2 [3], демонстрирующего корреляцию $r \geq 0.94$ с реальным MOS на тест-сплитах VoiceMOS Challenge [8]; (iv) публикация исходных аудиозаписей в открытом доступе позволяет любой третьей стороне применить свои собственные слушательские или автоматические метрики поверх наших данных.

Оценка проводится по пяти метрикам: UTMOSv2 и NISQA [4] для естественности; Whisper-WER (faster-whisper *medium*, int8 на CPU, с базовой нормализацией текста через `jiwer`: нижний регистр, удаление пунктуации, схлопывание пробелов) для разборчивости; WavLM [5] (`microsoft/wavlm-base-plus-sv` с x-vector головой) и

ECAPA-TDNN [6] (speechbrain/spkrec-ecapa-voxceleb) для схожести с диктором в задаче voice cloning. Параллельно фиксируются стоимость одной генерации (USD/файл, по официальным ratecards провайдеров) и скорость генерации (стенное время от запроса до получения полного аудиобуфера). Для интерпретации абсолютных значений speaker similarity дополнительно вычислены калибровочные якоря *same-speaker* и *cross-speaker* (Таблица 1).

2 Обзор литературы

Сравнительные исследования качества систем синтеза речи можно разнести по трём сложившимся формам. Первая — открытые лидерборды на основе слушательских оценок: TTS Arena [7] ранжирует системы по ELO-рейтингу от случайных слушателей и приводит UTMOSv2 как вторичную метрику; к ограничениям относятся непрозрачность исходного набора текстов, отсутствие задачи voice cloning, неучёт стоимости и зависимость рейтинга от ежедневно меняющегося пула. Вторая форма — бенчмарки на статичных корпусах в статьях, сопровождающих релизы конкретных моделей (Seed-TTS [31], CosyVoice 2 [9], CosyVoice 3 [36], XTTS [10], F5-TTS [11], VALL-E [38] и VALL-E 2 [39], NaturalSpeech [40] и NaturalSpeech 2 [41]); как правило, они сравнивают предлагаемую модель с открытыми предшественниками на собственной выборке. Третья форма — маркетинговые материалы коммерческих провайдеров, где сравнение проводится с закрытыми данными и закрытым набором метрик, что исключает независимую верификацию.

Сквозная проблема всех трёх форм — слабая **воспроизводимость** и почти полное отсутствие работ, которые одновременно (а) публикуют не только числа, но и сами синтезированные аудиозаписи, и (б) явно сравнивают *ранжирования*, порождаемые разными метриками одного семейства. Именно эти два требования — ось, по которой настоящая работа отличается от предшественников; ниже мы проходим по трём гипотезам работы и для каждой указываем релевантную литературу.

2.1 Воспроизводимость и обоснование автоматических метрик

Прямая оценка слушателями (MOS) считается «золотым стандартом», но плохо воспроизводима. Chiang, Huang и Lee [13] на выборке из 80 статей INTERSPEECH 2022 показывают, что детали слушательских тестов почти нигде не сообщаются, и — что важнее — на одних и тех же аудио, но при разных настройках теста получают как минимум три различных ранжирования тех же TTS-моделей. Cooper, Huang, Toda и Yamagishi [14] демонстрируют, что автоматические MOS-предикторы хорошо работают внутри своего теста, но плохо обобщаются на новые контексты

прослушивания, причём невиданные системы — особенно тяжёлый случай. Эти две работы — основное обоснование нашего выбора в пользу исключительно автоматических, полностью воспроизводимых метрик и публикации самих аудио для независимой переоценки (ср. позиционную работу об ответственной оценке TTS [15]). UTMOSv2 [3] (наследник UTMOS [17], победитель VoiceMOS Challenge [8] в варианте T05 [18]) и NISQA [4, 19] служат стандартными прокси естественности; дистрибутивные бенчмарки TTSDS [20] и TTSDS2 [21], а также Audio Turing Test [24] и SOMOS [12] образуют современный методологический контекст. Воспроизводимых работ, публикующих и метрики, и аудио, и при этом сравнивающих между собой ранжирования метрик, в литературе крайне мало — этот пробел мы и закрываем.

2.2 Контекст гипотезы H1: многокритериальность и отсутствие доминирующей модели

Гипотеза H1 утверждает, что в многомерном пространстве (естественность, разборчивость, схожесть с диктором, стоимость, скорость) не существует доминирующей модели. Большинство модельно-ориентированных бенчмарков измеряют две оси — WER и speaker similarity (SIM): протокол Seed-TTS [31] вычисляет WER через Whisper [32] и SIM через эмбединги WavLM [5], и именно этот протокол де-факто воспроизводят CosyVoice 2/3 [9, 36], Qwen3-TTS [37] и др. Однако такие сравнения почти никогда не включают стоимость и скорость как самостоятельные оси. Отдельная работа об отзывчивости open-source TTS [25] сдвигает фокус именно на latency/throughput, но не объединяет его с качеством и не охватывает коммерческие API.

Прямых сравнений коммерческих и open-source систем в одном эксперименте мало, и их выводы неоднородны. EmergentTTS-Eval [26] оценивает и проприетарные (ElevenLabs, Deepgram, OpenAI 4o-mini-tts), и открытые системы через model-as-a-judge на сложных просодических кейсах и фиксирует разрыв в пользу закрытых моделей по ряду аспектов. Работа о Human Fooling Rate [27] сравнивает 5 коммерческих и 5 open-source систем на слух 135 участников и приходит к выводу, что коммерческие модели ближе к «человеческой неотличимости» на разговорной речи, тогда как open-source отстают. Эти работы измеряют другие домены и метрики, чем наша (нейтральная студийная речь, автоматические метрики), и потому их выводы дополняют, а не противоречат нашим: они показывают, что положение Парето-фронта существенно зависит от выбора осей. Аналогичные сравнения «платное vs открытое» в соседней задаче ASR (например, бенчмарк PennSound) традиционно находят преимущество платных сервисов — контраст, на фоне которого наш результат становится содержательным, а не ожидаемым.

2.3 Контекст гипотезы H2: согласованность метрик и важность выбора эмбедингов

Гипотеза H2 проверяет согласованность системных рангов внутри двух семейств метрик: естественности (UTMOSv2 vs NISQA) и схожести с диктором (WavLM vs ECAPA).

Естественность: расхождение и его механизм. Принципиально важно, что мы не ограничиваемся констатацией «метрики расходятся», а опираемся на признанный в литературе механизм. Во-первых, MOS-предикторы плохо обобщаются между тестовыми контекстами и системами [14], поэтому две независимо обученные модели могут давать разный сигнал на новой выборке провайдеров. Во-вторых, для SOTA-систем объективные метрики страдают *насыщением шкалы*, что делает ранжирование, особенно по предиктивным MOS-метрикам, ненадёжным: это прямо показано в работе об итеративном различении (I2D) [16] и согласуется с наблюдениями TTSDS [20] о том, что MOS-предикторы лишь иногда коррелируют с человеческими оценками и в целом не обобщаются. Эти два механизма — ограниченная обобщаемость и насыщение — объясняют наблюдаемое у нас расхождение UTMOSv2 и NISQA и низкую системную корреляцию между ними; NISQA, исторически разработанная для оценки канала и кодека, упирается в верхнюю границу шкалы у коммерческих провайдеров с чистым каналом.

Схожесть с диктором: выбор эмбедингов имеет значение. Косинусная близость speaker-эмбедингов между опорной и синтезированной записью — основная объективная метрика клонирования; её валидность как прокси MUSHRA-оценок показана в [29], а на её основе построен открытый бенчмарк клонирования ClonEval [22]. При этом результат зависит от того, *какой* энкодер выбран. Специальное исследование [28] сравнивает ECAPA-TDNN, x-vector и H/ASP как энкодеры для оценки speaker similarity в zero-shot multi-speaker TTS и находит, что выбор энкодера влияет на оценку (ECAPA опережает x-vector, но оригинальный H/ASP стабильно лучше обоих), и подчёркивает необходимость эмпирической проверки при переиспользовании эмбедингов из задач распознавания диктора. Эта работа важна как явный контрапункт нашему результату H2.similarity: на уровне отдельных высказываний выбор энкодера небезразличен, тогда как мы обнаруживаем, что на *системном* уровне WavLM [5] (x-vector голова) и ECAPA-TDNN [6] ранжируют провайдеров почти идентично. Эти два наблюдения не противоречат друг другу, а уточняют область применимости: для финального ранжирования систем достаточно одной метрики семейства, хотя на уровне utterance выбор энкодера ещё может играть роль (ср. также применение ECAPA как

speaker encoder в multi-speaker TTS [30]). Систематических работ, которые бы сравнивали именно *ранжирования* двух метрик одного семейства между собой (а не их корреляцию с человеком), практически нет — это самостоятельный вклад нашей Н2.

2.4 Контекст гипотезы Н3: эквивалентность вместо различия

Гипотеза Н3 формулируется как утверждение об *эквивалентности* коммерческой и open-source групп в пределах методологически значимого порога δ , а не как тест на различие. Это методологически нетипично для области синтеза речи. Сложившаяся практика сравнения TTS ориентирована именно на обнаружение различий — характерна уже работа Chevelu et al. [35] с подзаголовком «methodology focused on differences», где отмечается, что случайный выбор сэмплов сглаживает различия и приводит к ложному выводу о незначимости улучшения. Заявления о «human parity» также строятся на тестах различия: NaturalSpeech [40] объявляет паритет с человеком через отсутствие статистически значимой разницы в Wilcoxon-тесте. Между тем отсутствие значимого различия не равно эквивалентности — именно это разграничение лежит в основе процедуры TOST (two one-sided tests), для которой каноническими методологическими ссылками служат Lakens [33] и Lakens, Scheel и Isager [34]: задаётся наименьший интересующий эффект δ и проверяются две односторонние гипотезы, причём авторы прямо предупреждают о распространённой ошибке вывода «эффекта нет» из статистической незначимости. Применений TOST/non-inferiority-тестирования к сравнению TTS-систем в литературе мы не обнаружили, что делает методологию Н3 самостоятельным вкладом.

Содержательно наш вывод Н3 (на ключевых для пользователя осях — разборчивости и схожести голоса — open-source эквивалентен коммерческим) нетривиален, поскольку доминирующий нарратив и часть свежих работ утверждают обратное: разрыв в пользу закрытых систем фиксируют EmergentTTS-Eval [26] на сложных кейсах и работа о Human Fooling Rate [27] на разговорной речи. Одновременно независимые релизы подтверждают, что разрыв на стандартных осях закрывается: CosyVoice3 [36] заявляет SOTA по content consistency, speaker similarity и prosody naturalness, а Qwen3-TTS [37] — наименьший WER на Seed-TTS и превосходство над коммерческими MiniMax и ElevenLabs по speaker similarity. То, что именно линейка CosyVoice оказывается у нас универсально Парето-оптимальной, согласуется с этим трендом. Наконец, подтверждённая нами эквивалентность по Whisper-WER не является артефактом: поскольку у современных систем разборчивость упирается в «пол» (WER, близкий к реальной речи; см. [21, 16]), дискриминирующий сигнал смещается с WER на естественность и схожесть, и потому информативны именно два случая, где разрыв превышает δ в

противоположные стороны.

2.5 Пробел в литературе

Суммируя, в существующей литературе не обнаружено работ, удовлетворяющих одновременно условиям: (а) совместное сравнение коммерческих API и open-source моделей в едином эксперименте на едином корпусе и наборе метрик; (б) явный учёт стоимости и скорости генерации как самостоятельных осей; (в) публичная доступность как численных результатов, так и самих синтезированных аудиозаписей для независимой переоценки; (г) прямое сравнение *ранжирований*, порождаемых разными метриками одного семейства (естественность; схожесть с диктором); (д) постановка вопроса о паритете лагерей как формального теста *эквивалентности* (TOST), а не теста на различие. Настоящая работа закрывает указанный пробел.

3 Цель и вопросы работы

Основной исследовательский вопрос: *какие из современных систем синтеза речи и клонирования голоса составляют Парето-оптимальное множество в пространстве (естественность, разборчивость, схожесть с диктором, стоимость, скорость генерации) на корпусе LibriTTS-R test-clean (английская студийная речь), и достигла ли группа open-source моделей в среднем эквивалентности с группой коммерческих провайдеров по качественным метрикам в пределах методологически значимого порога δ ?*

Этот вопрос декомпозируется в три формальные гипотезы, проверяемые в Разделе 6:

- **H1** (Парето-оптимальность моделей). Не существует модели, парето-доминирующей над всеми остальными в многомерном пространстве оценок: для TTS — (UTMOSv2, NISQA, Whisper-WER, стоимость); для voice cloning — (UTMOSv2, NISQA, WavLM-similarity, Whisper-WER, стоимость).
- **H2** (Согласованность метрик). Для естественности (UTMOSv2 vs NISQA) ожидается согласованность системных рангов ($\rho_{\text{Spearman}} \geq 0.7$), поскольку обе метрики номинально измеряют одно и то же свойство. Для speaker similarity (WavLM vs ECAPA) ожидается расхождение ($\rho < 0.7$), поскольку модели имеют разные архитектуры и могут давать разный сигнал. Подтверждение каждой из двух подгипотез означало бы возможность ограничиться одной метрикой в соответствующем семействе.
- **H3** (Эквивалентность лагерей). На стандартизованном тесте LibriTTS-R *test-clean* коммерческие TTS-провайдеры в среднем не превосходят open-source модели по качественным метрикам более чем на методологически значимый

порог δ (TOST-тест с $\delta = 0.2$ для UTMOSv2/NISQA, $\delta = 0.05$ для WER и speaker similarity).

Цель работы. Построить воспроизводимый бенчмарк современных TTS- и voice-cloning-систем на едином корпусе и едином наборе метрик, формализовать сравнительные гипотезы и проверить их статистически. Все артефакты (синтезированные аудиозаписи, метрики, скрипты) выложены публично; повторение эксперимента занимает порядка двух суток на одной видеокарте NVIDIA RTX 4090.

Вклад работы.

- Собран открытый бенчмарк из 6680 аудиозаписей с фиксированным манифестом текстов и опорных записей.
- Реализован унифицированный pipeline, объединяющий пять автоматических метрик качества, а также измерения скорости генерации и стоимости, что устраняет вариативность методологии между провайдерами.
- Сформулированы и статистически проверены три гипотезы: о Парето-оптимальности (H1), согласованности метрик (H2) и эквивалентности commercial и OSS групп по качественным метрикам (H3, TOST с практически значимыми порогами δ).
- Публично выложены сами синтезированные аудиозаписи (на сетевом хранилище проекта), что позволяет независимым исследователям пересчитать наши метрики или применить альтернативные, в том числе человеческие.

4 Автоматические метрики

4.1 Корпуса для оценки TTS

LibriTTS [1] — стандартный корпус для исследований нейронного TTS, содержащий 585 часов английской речи 2456 дикторов; разделён на чистые и шумные части, сопровождается тщательной нормализацией текстов. LibriTTS-R [2] — его улучшенная версия с применённой моделью DEMUCS для шумоподавления. Подвыборка *test-clean* содержит 39 дикторов и широко используется как тестовый сплит в работах по few-shot voice cloning.

4.2 UTMOSv2 как прокси MOS

UTMOSv2 [3] — модель предсказания Mean Opinion Score, обученная на корпусах MOS-аннотированных пар (*stimulus*, *score*) с применением Self-Supervised Learning

эмбеддингов WavLM. Достигает корреляции Пирсона $r \geq 0.94$ с реальным MOS на test-сплитах конкурсов VoiceMOS Challenge. В TTS Arena (Hugging Face) UT-MOSv2 используется как единая ось ранжирования. Ограничения: значения сжаты в диапазон 3.2–4.0 для современных систем, выдаваемые «как есть» интерпретировать как MOS не следует.

4.3 NISQA

NISQA [4] — многомерная модель оценки качества телефонной речи, выдаёт пять величин: общее MOS и четыре сабскопа (Noisiness, Coloration, Discontinuity, Loudness). Предназначена изначально для оценки кодеков и каналов связи, но активно используется и для TTS. В наших экспериментах наблюдается насыщение шкалы NISQA для коммерческих TTS-провайдеров: значения упираются в верхнюю границу около 5.0.

4.4 Whisper-WER как метрика разборчивости

Word Error Rate = $(S + D + I)/N$, где S, D, I, N — количество замен, удалений, вставок и общее число слов в эталонной транскрипции, является стандартом для измерения разборчивости синтетической речи. В качестве ASR-системы выбран *faster-whisper-medium* (соответствует выбору в открытом бенчмарке TTSDS, что упрощает сравнение результатов), запущенный в режиме int8 на CPU.

4.5 Speaker similarity

Cosine similarity speaker-эмбеддингов между опорной записью диктора и синтезированным аудио — основная объективная метрика качества voice cloning. Используются две независимые модели:

- **WavLM speaker embedding** [5]: модель `microsoft/wavlm-base-plus-sv` (WavLM-Base+, дообученная на VoxCeleb для задачи speaker verification, выход — x-vector). Калиброванный нами same-speaker p_{50} составляет 0.958, cross-speaker mean — 0.686.
- **ESCAPA-TDNN** [6]: классический speaker recognition бэкбон с emphasized channel attention. Same-speaker $p_{50} = 0.703$, cross-speaker mean = 0.223 — более широкий динамический диапазон, чем у WavLM.

Калибровочные якоря (Таблица 1) позволяют интерпретировать абсолютные значения схожести.

Table 1: Калибровочные якоря для метрик speaker similarity. «Same-speaker» — cosine similarity между двумя независимыми утверждениями одного диктора (верхняя граница). «Cross-speaker» — схожесть между разными дикторами (нижняя граница).

Метрика	Same-speaker p_{50}	Same-speaker mean $\pm$ std	N_{up}	Cross-speaker mean $\pm$ std	N_{lo}
WAVLM	0.958	0.946 ± 0.051	100	0.686 ± 0.170	190
ECAPA	0.703	0.676 ± 0.153	100	0.223 ± 0.118	190

5 Методология

5.1 Дизайн эксперимента

Эксперимент построен по факториальной схеме «провайдер × задача × диктор × утверждение». Из *test-clean* LibriTTS-R случайно отобраны 20 дикторов (10 мужчин + 10 женщин), сбалансированных по полу. Для каждого диктора выбраны 20 утверждений с эталонной аудиозаписью длительностью 2–15 секунд, что даёт 400 пар (диктор, текст) на (провайдер, задача); эмпирический диапазон длины текстов в выборке составляет 14–283 символа. Для voice-cloning задачи в качестве reference берётся одна 5–10-секундная запись того же диктора, не входящая в целевые 20 утверждений.

Каждая (провайдер, задача) комбинация даёт ровно 400 аудиозаписей, кроме исключений:

- **Typecast** и **Resemble** были проверены только на задаче voice cloning (TTS-режим у этих провайдеров отсутствует).
- У **Resemble** 6 дикторов из 20 имеют опорную запись короче 10 секунд, что нарушает требования rapid-clone эндпоинта; они исключены, итого 280 файлов в cloning-задаче.

Итоговый объём сгенерированного корпуса — 6680 файлов; перечень всех строк, попадающих в анализ, приведён в Таблице 2.

Table 2: Размеры выборок: количество файлов с непустым значением каждой метрики, по (провайдер × задача). Прочерк — метрика неприменима. Cloning-строки Azure / Google / OpenAI отсутствуют, поскольку эти провайдеры не имеют voice-cloning эндпоинта и не выполняли задачу клонирования голоса; их файлы исключены из всех cloning-аналитик.

Провайдер	Задача	Файлов	UTMOSv2	NISQA	WER	WavLM	ECAPA
Azure Neural	TTS	400	400	400	400	0	0
CosyVoice2	TTS	400	400	400	400	0	0
	Cloning	400	400	400	400	400	400
ElevenLabs	TTS	400	400	400	400	0	0
	Cloning	400	400	400	400	400	400
F5-TTS	TTS	400	400	400	400	0	0
	Cloning	400	400	400	400	400	400
Fish-Speech S1	TTS	400	400	400	400	0	0
	Cloning	400	400	400	400	400	400
Fish-Speech S2 Pro	TTS	400	400	400	400	0	0
	Cloning	400	400	400	400	400	400
Google Neural2	TTS	400	400	400	400	0	0
OpenAI tts-1	TTS	400	400	400	400	0	0
Resemble	Cloning	280	280	280	280	280	280
Typecast	Cloning	400	400	400	400	400	400
XTTSv2	TTS	400	400	400	400	0	0
	Cloning	400	400	400	400	400	400

5.2 Перечень моделей

Шесть коммерческих API: *ElevenLabs* (Multilingual v2 + IVC clone), *OpenAI TTS* (tts-1, voice = alloy), *Azure Neural Speech* (en-US-AvaMultilingualNeural), *Google Cloud TTS* (Neural2-F), *Typecast* (SSFm-v30) и *Resemble AI* (rapid clone). Пять open-source моделей: *Coqui XTTSv2*, *F5-TTS*, *Alibaba CosyVoice2-0.5B*, *FishAudio Fish-Speech S1-mini* и *Fish-Speech S2 Pro*. Все open-source модели запускались на одном NVIDIA RTX 4090 (24 ГБ); веса кэшировались на NFS-хранилище между запусками.

Замечание о cloning-задаче. Azure Neural Speech, Google Cloud TTS и OpenAI tts-1 не имеют voice-cloning-эндпоинта: при обращении они синтезируют речь фиксированным голосом провайдера и игнорируют опорную запись диктора. Их строки в cloning-задаче технически генерируются (для возможности расчёта UTMOSv2, NISQA, WER, latency и cost), однако **исключаются из всех cloning-аналитик** (Парето-фронт, тесты H1.cloning, H2.cloning, H3.cloning), поскольку структурно эти провайдеры не выполняли оцениваемую задачу. Все вердикты по cloning формируются на 8 моделях: ElevenLabs, Typecast, Resemble, XTTSv2, F5-TTS, CosyVoice2, Fish-Speech S1, Fish-Speech S2 Pro.

5.3 Метрики

Каждая запись оценивается следующими автоматическими судьями:

- UTMOSv2 (`sarulab-speech/UTMOSv2`, версия 0.4) — наследник UTMOS, инференс на CPU вследствие нестабильности GPU-пути на CUDA 13.
- NISQA-MOS + 4 сабскопа (модель Mittag, `dnsmos-style`).
- Whisper-WER: *faster-whisper medium* (вариант, использованный также в TTSDS-бенчмарках), int8 на CPU, расчёт через библиотеку `jiwer.Compose` с базовой нормализацией: `ToLowerCase + RemovePunctuation + RemoveMultipleSpaces + Strip + ReduceToListOfListOfWords`.
- WavLM speaker embedding: `microsoft/wavlm-base-plus-sv` через `AutoModelForAudioXVector` (x-vector голова), исключительно на cloning-задаче.
- ECAPA-TDNN cosine sim: `speechbrain/spkrec-ecapa-voxceleb`, аналогично.

Cost (USD) рассчитывается из официальных rate-card провайдеров (см. Таблицу 5) умножением на число символов исходного текста. Latency измеряется как стенное время от вызова `POST` до получения полного аудиобуфера (для облачных API) или от вызова `model.generate()` до завершения декодирования (для локальных моделей).

5.4 Калибровка метрик speaker similarity

Абсолютные значения cosine similarity WavLM и ECAPA не имеют интуитивной шкалы. Для интерпретации мы вычисляем два якоря:

- **Верхний** (same-speaker): схожесть между двумя независимыми записями одного диктора. Усреднение по 100 случайным парам.
- **Нижний** (cross-speaker): схожесть между записями разных дикторов. Усреднение по 190 случайным парам.

Используя медиану верхнего якоря, можно нормализовать наблюдаемые значения схожести и интерпретировать их как процент достижения «потолка» same-speaker.

6 Гипотезы

6.1 H1: отсутствие доминирующей модели

Формулировка. Не существует модели, парето-доминирующей над всеми остальными в многомерном пространстве «качество, стоимость» при дефолтных настройках inference.

Операционализация. Для каждой задачи строится Парето-фронт в пространстве, включающем все измеренные оси качества плюс стоимость:

- TTS (4 оси): (UTMOSv2, NISQA, WER, cost_usd), направления оптимизации: $\uparrow, \uparrow, \downarrow, \downarrow$.
- Cloning (5 осей): (UTMOSv2, NISQA, WavLM-sim, WER, cost_usd), направления: $\uparrow, \uparrow, \uparrow, \downarrow, \downarrow$.

Гипотеза подтверждается, если на фронте находятся ≥ 2 моделей. Дополнительно проводится анализ чувствительности: показывается, как размер фронта меняется при удалении/добавлении отдельных осей (см. Раздел 7.4.1).

6.2 H2: согласованность метрик одного типа

H2.naturalness. UTMOSv2 и NISQA — независимо обученные модели предсказания качества, поэтому их системные ранги должны коррелировать. Порог: $\rho_{\text{Spearman}} \geq 0.7$.

H2.similarity. WavLM и ECAPA имеют разные архитектуры (трансформер vs TDNN), поэтому могут расходиться. Гипотеза подтверждается, если $\rho_{\text{Spearman}} < 0.7$.

6.3 H3: эквивалентность коммерческой и open-source групп

Формулировка. На стандартизованном тесте LibriTTS-R *test-clean* коммерческие TTS-провайдеры в среднем не превосходят open-source модели по качественным метрикам (UTMOSv2, NISQA, Whisper-WER, WavLM-sim, ECAPA-sim) более чем на методологически значимый порог δ_{qual} :

- $\delta_{\text{UTMOS}} = \delta_{\text{NISQA}} = 0.2$ единицы (по шкале 1–5);
- $\delta_{\text{WER}} = 0.05$ (5 процентных пунктов абсолютной WER);
- $\delta_{\text{WavLM-sim}} = \delta_{\text{ECAPA-sim}} = 0.05$ (cosine similarity).

Значения δ выбраны заведомо меньшими, чем эффекты, заметные конечному пользователю на отдельной записи; их превышение мы интерпретируем как практически значимый разрыв между лагерями.

Операционализация. Для каждой метрики применяется двусторонний тест эквивалентности TOST (Two One-Sided Tests) на провайдер-уровневых средних в двух группах:

$$\begin{aligned} H_{0,\text{TOST}} : |\bar{x}_{\text{commercial}} - \bar{x}_{\text{open-source}}| &\geq \delta \quad (\text{не-эквивалентность}), \\ H_{1,\text{TOST}} : |\bar{x}_{\text{commercial}} - \bar{x}_{\text{open-source}}| &< \delta \quad (\text{эквивалентность}). \end{aligned}$$

Эквивалентность считается подтверждённой, если оба односторонних p -value ниже $\alpha = 0.05$; в этом случае коммерческие системы в среднем не превосходят open-source более чем на δ по соответствующей метрике. Гипотеза проверяется по отдельности для каждой комбинации (задача, метрика); для метрик speaker similarity в задаче

voice cloning из выборки исключены провайдеры без zero-shot эндпоинта (Azure, Google, OpenAI).

7 Результаты

7.1 Сводные ранжирования

Таблицы 3 и 4 показывают средние значения метрик с 95%-ными бутстрап-доверительными интервалами ($B = 1000$ ресэмплов, метод `basic` в `scipy.stats.bootstrap`) для каждой комбинации (провайдер, задача).

Table 3: Средние значения метрик с 95% бутстрап-доверительными интервалами по провайдерам (задача: TTS). $N=400$ на ячейку для большинства комбинаций.

Провайдер	UTMOSv2	NISQA	WER	Cost (USD)	Скорость (с)
CosyVoice2	3.95 ± 0.03	4.74 ± 0.02	0.038 ± 0.008	0.0000 ± 0.0000	5.51 ± 0.22
Azure Neural	3.83 ± 0.02	4.78 ± 0.02	0.036 ± 0.008	0.0018 ± 0.0001	1.40 ± 0.05
Google Neural2	3.74 ± 0.02	5.01 ± 0.02	0.036 ± 0.008	0.0018 ± 0.0001	0.30 ± 0.01
OpenAI tts-1	3.72 ± 0.03	4.91 ± 0.02	0.037 ± 0.008	0.0016 ± 0.0001	2.03 ± 0.14
ElevenLabs	3.65 ± 0.03	5.01 ± 0.02	0.037 ± 0.008	0.0035 ± 0.0004	1.31 ± 0.03
F5-TTS	3.60 ± 0.03	4.77 ± 0.03	0.040 ± 0.009	0.0000 ± 0.0000	1.27 ± 0.03
Fish-Speech S2 Pro	3.51 ± 0.03	4.45 ± 0.05	0.039 ± 0.008	0.0000 ± 0.0000	37.03 ± 1.92
XTTSv2	3.43 ± 0.03	4.76 ± 0.03	0.038 ± 0.008	0.0000 ± 0.0000	2.88 ± 0.15
Fish-Speech S1	3.40 ± 0.03	4.04 ± 0.07	0.044 ± 0.009	0.0000 ± 0.0000	12.13 ± 0.55

Table 4: Средние значения метрик с 95% бутстрап-доверительными интервалами по провайдерам (задача: Voice Cloning). $N=400$ на ячейку для большинства комбинаций.

Провайдер	UTMOSv2	NISQA	WER	WavLM	ECAPA	Cost (USD)	Скорость (с)
CosyVoice2	3.67 ± 0.03	4.71 ± 0.03	0.043 ± 0.009	0.964 ± 0.002	0.788 ± 0.006	0.0000 ± 0.0000	5.22 ± 0.21
Resemble	3.66 ± 0.04	4.91 ± 0.02	0.035 ± 0.009	0.937 ± 0.004	0.630 ± 0.010	0.0100 ± 0.0006	3.67 ± 0.17
ElevenLabs	3.47 ± 0.03	4.72 ± 0.03	0.036 ± 0.008	0.938 ± 0.004	0.640 ± 0.010	0.0072 ± 0.0004	1.13 ± 0.04
Fish-Speech S1	3.46 ± 0.04	4.78 ± 0.03	0.043 ± 0.009	0.950 ± 0.003	0.700 ± 0.010	0.0000 ± 0.0000	13.45 ± 0.64
Fish-Speech S2 Pro	3.40 ± 0.04	4.73 ± 0.03	0.037 ± 0.008	0.960 ± 0.002	0.713 ± 0.008	0.0000 ± 0.0000	36.18 ± 1.79
XTTSv2	3.25 ± 0.04	4.49 ± 0.04	0.040 ± 0.008	0.947 ± 0.003	0.684 ± 0.009	0.0000 ± 0.0000	2.89 ± 0.15
F5-TTS	3.22 ± 0.04	4.82 ± 0.03	0.043 ± 0.009	0.963 ± 0.002	0.775 ± 0.007	0.0000 ± 0.0000	1.20 ± 0.01
Typecast	3.18 ± 0.05	4.82 ± 0.03	0.034 ± 0.008	0.951 ± 0.002	0.726 ± 0.006	0.0156 ± 0.0008	1.45 ± 0.06

В TTS-задаче по UTMOSv2 лидирует cosyvoice2 (3.950), что неожиданно, поскольку это open-source модель. Однако по NISQA лидеры — google_tts и ElevenLabs (оба ≈ 5.01 и упёрлись в верхнюю границу шкалы; Azure следует с 4.78, OpenAI — с 4.91). Худший по UTMOSv2 в TTS — fish_speech_s1 (3.403). По WER все модели располагаются в коридоре 3.6–4.4%; разница незначима с учётом ширины CI (~ 0.8 п.п.).

В voice-cloning-задаче картина меняется радикально. cosyvoice2 лидирует по UTMOSv2 (3.666), cosyvoice2 — по WavLM speaker similarity (0.964, при калибровочном

same-speaker уровне 0.958). Это означает, что лучшая модель достигает $\sim 0.964 / 0.958 \approx \sim 100\%$ от потолка человеческого same-speaker similarity на WavLM. На ЕСАРА картина схожая, но дельта между топ-1 и топ-2 заметно больше.

7.2 Стоимость

Table 5: Стоимость синтеза по провайдерам. «Цена / 1М симв.» — официальная цена по pricing page. «\$ / файл» — средняя стоимость одного из наших файлов (~ 110 симв.). «Фактич. расход» — сумма реально потраченных средств за весь эксперимент (800 файлов на коммерческого провайдера).

Провайдер	Тип	Цена / 1М симв., USD	\$ / файл	Фактич. расход
OpenAI tts-1	коммерч.	15.00	0.00164	\$1.31
Azure Neural	коммерч.	16.00	0.00175	\$1.40
Google Neural2	коммерч.	16.00	0.00175	\$1.40
ElevenLabs	коммерч.	66.00	0.00723	\$4.29
Resemble	коммерч.	87.59	0.01001	\$2.80
Typecast	коммерч.	142.66	0.01562	\$6.25
XTTSv2	open-source	0 (open-source)	0.00000	—
F5-TTS	open-source	0 (open-source)	0.00000	—
CosyVoice2	open-source	0 (open-source)	0.00000	—
Fish-Speech S1	open-source	0 (open-source)	0.00000	—
Fish-Speech S2 Pro	open-source	0 (open-source)	0.00000	—

Таблица 5 раскрывает существенный разброс: Google TTS и Azure — самые дешёвые коммерческие провайдеры (\$16/1М симв.), Typecast — самый дорогой (\$143/1М симв., в ~ 9 раз дороже Google и в 2.2 раза дороже ElevenLabs). При этом по метрикам качества Typecast не превосходит ни Google, ни ElevenLabs (см. ниже H1.cloning). Open-source модели бесплатны при инференсе (кроме амортизации GPU), что даёт им асимптотическое преимущество при больших объёмах.

7.3 Скорость генерации

В Таблицах 3 и 4 колонка «Скорость (с)» содержит среднее время генерации одного файла. Скорость генерации определяется как стенное время от вызова POST-запроса (для облачных API) или метода `model.generate()` (для локальных моделей) до получения полного аудиобуфера в памяти процесса. Замеры производились последовательно, без батчинга, на одной видеокарте NVIDIA RTX 4090 для open-source моделей и через интернет-канал из российского сегмента сети для коммерческих API. Средняя длина целевого аудио составляла около 7 секунд.

Диапазон наблюдаемых значений охватывает более двух порядков величины. В TTS-задаче самой быстрой моделью оказалась `google_tts` со средним временем

генерации 0.302 с/файл; самой медленной — fish_speech_s2_pro (37.030 с/файл). В voice-cloning-задаче картина аналогична: elevenlabs обеспечивает 1.131 с/файл, fish_speech_s2_pro — 36.177 с/файл.

Обнаруженный разрыв в ~ 120 раз между лучшей и худшей моделью имеет прямые практические последствия. Для интерактивных голосовых интерфейсов (диалоговые ассистенты, real-time-озвучивание) допустимо время отклика не более 1–2 секунд: этому требованию удовлетворяют только Google TTS, ElevenLabs и Azure Neural Speech. Все локальные open-source модели на одной 4090 не подходят для интерактивного режима без батчинга или квантования (XTTSv2 — ~ 3 с/файл, F5-TTS — ~ 1.3 с/файл, остальные — значительно дольше). Особенно медленна Fish-Speech S2 Pro (≈ 37 с/файл), использующая авторегрессионный декодер без оптимизации под одиночный инференс; Fish-Speech S1 в 3 раза быстрее (≈ 12 с/файл). На Парето-фронтах (Рис. 1 и 2) latency сама по себе не отображается как ось, поскольку для интерактивного сценария применения определяющей является не столько оптимальность по latency, сколько превышение порога 1–2 секунд: облачные API и open-source решения занимают принципиально разные регионы по этому критерию.

7.4 H1: Парето-оптимальность

TTS. Основная проекция включает четыре оси — (UTMOSv2, NISQA, Whisper-WER, cost_usd). Парето-фронт содержит 6 из 9 моделей: Azure Neural, CosyVoice2, F5-TTS, Google Neural2, OpenAI tts-1, XTTSv2. Гипотеза H1.tts **подтверждена**.

Cloning. Основная проекция включает пять осей — (UTMOSv2, NISQA, WavLM-sim, Whisper-WER, cost_usd). Парето-фронт содержит 7 из 8 моделей: CosyVoice2, ElevenLabs, F5-TTS, Fish-Speech S1, Fish-Speech S2 Pro, Resemble, Typecast. Единственная модель, не попавшая на фронт — XTTSv2: над ней доминирует Fish-Speech S2 Pro одновременно по UTMOSv2 (3.40 vs 3.25), NISQA (4.73 vs 4.49), WavLM-sim (0.960 vs 0.947) и Whisper-WER (0.037 vs 0.040), при равной стоимости (open-source, ≈ 0). Гипотеза H1.cloning **подтверждена**.

7.4.1 Анализ чувствительности Парето-фронта

Парето-фронт по построению чувствителен к выбору осей: добавление новой оси, на которой какая-то модель является лидером, делает её недоминируемой. Это особенно важно для нашего случая, поскольку метрики naturalness (UTMOSv2, NISQA) согласуются слабо (см. результаты H2 ниже), а значит, несут частично ортогональный сигнал и расширяют фронт.

Таблица 6 показывает результаты анализа чувствительности — размер и состав фронта при различных наборах осей. Ключевые наблюдения:

- Если в TTS использовать только две оси (UTMOSv2, cost), на фронте остаётся одна модель — CosyVoice2. С добавлением WER к ней добавляются Azure Neural, Google Neural2 и OpenAI tts-1 (итого 4 модели); с дальнейшим включением NISQA — F5-TTS и XTTSv2 (итого 6).
- Для cloning канонический 3D-фронт (UTMOSv2, WavLM-sim, cost) содержит единственную доминирующую модель CosyVoice2. С добавлением WER на фронт возвращаются 5 моделей: все три коммерческих cloning-провайдера (ElevenLabs, Typecast, Resemble), оптимизированных под минимальный WER ценой меньшей speaker similarity, плюс Fish-Speech S1 и Fish-Speech S2 Pro. С добавлением NISQA на фронт попадает F5-TTS.
- Таким образом, нарратив «CosyVoice2 парето-доминирует все остальные cloning-системы» справедлив только для упрощённой 3D-проекции и теряется при учёте всех измеренных характеристик. Это согласуется с теоретическим ожиданием: чем больше осей качества, тем больше точек оказывается на фронте.

CosyVoice2 присутствует на фронте во всех проекциях обеих задач, что делает её *универсально парето-оптимальной* моделью в нашем эксперименте. Никакая другая система этим свойством не обладает.

Рис. 1 и 2 визуализируют упрощённые двумерные проекции Парето-фронта для обеих задач. Полное многомерное вычисление с использованием всех осей (4D для TTS, 5D для cloning) формирует основной вердикт H1; двумерные проекции служат для визуальной интерпретации отдельных компромиссов. На каждой панели применяется двухуровневая визуализация: **золотой** контур обозначает модель, входящую в *полный многомерный* Парето-фронт; **серебряный** — модель, парето-оптимальную только в данной 2D-проекции (доминируемую в полной размерности); **чёрный** — модель, доминируемую везде. Круги — коммерческие провайдеры, квадраты — open-source модели.




Figure 1: Двумерные проекции Парето-фронта для задачи Text-to-Speech, 2×3 панели — все возможные пары из четырёх измеренных осей (UTMOSv2, NISQA, Whisper-WER, cost). Верхний ряд: (a) UTMOSv2 vs NISQA, (b) UTMOSv2 vs WER, (c) UTMOSv2 vs Cost. Нижний ряд: (d) NISQA vs WER, (e) NISQA vs Cost, (f) WER vs Cost. Cost-оси — в логарифмической шкале; открытые модели (XTTSv2, F5-TTS, CosyVoice2, Fish-Speech) имеют нулевой инференс-cost и расположены на левой границе шкалы. Typecast и Resemble на этой фигуре отсутствуют, поскольку не поддерживают TTS-режим. **Кодирование обводки:** золотой контур — модель входит в полный 4D Парето-фронт ((UTMOSv2, NISQA, WER, cost), 6/9 моделей, перечислены в Таблице 6); серебряный контур — модель парето-оптимальна только в данной 2D-проекции, но доминируема в полной размерности; чёрный контур — доминируема и в 2D, и в полной размерности.




Figure 2: Двумерные проекции Парето-фронта для задачи voice cloning, 2×3 панели. Верхний ряд: (a) UTMOSv2 vs WavLM speaker similarity, (b) UTMOSv2 vs Whisper-WER, (c) UTMOSv2 vs Cost. Нижний ряд: (d) WavLM-sim vs WER, (e) WavLM-sim vs Cost, (f) WER vs Cost. На графиках представлены только провайдеры, выполняющие настоящее zero-shot клонирование голоса (ElevenLabs, Typecast, Resemble, XTTSv2, F5-TTS, CosyVoice2, Fish-Speech S1, Fish-Speech S2 Pro). Azure, Google и OpenAI **глобально исключены** из cloning-анализа, поскольку их cloning-эндпоинты используют фиксированные голоса и не учитывают опорную запись диктора — они структурно не выполняли задачу, оцениваемую в этом разделе. **Кодирование обводки:** золотой контур — модель входит в полный 5D Парето-фронт ((UTMOSv2, NISQA, WavLM-sim, WER, cost), 7/8 моделей, перечислены в Таблице 6); серебряный контур — парето-оптимальна только в данной 2D-проекции; чёрный контур — доминируема и в 2D, и в полной размерности.

Table 6: Sensitivity-анализ Парето-фронта: размер и состав фронта в зависимости от выбора измеренных осей. Первая строка для каждой задачи (выделена) — основная проекция, по которой формулируется verdict H1. Последующие строки — альтернативные проекции с удалением части осей; они показывают, как нетривиальность фронта зависит от количества измеряемых характеристик качества.

Задача	Оси проекции	На фронте / всего	Парето-оптимальные
TTS	UTMOSv2, NISQA, WER, Cost (USD)	6/9	Azure Neural, CosyVoice2, F5-TTS, Google Neural2, OpenAI tts-1, XTTSv2
TTS	UTMOSv2, WER, Cost (USD)	4/9	Azure Neural, CosyVoice2, Google Neural2, OpenAI tts-1
TTS	UTMOSv2, NISQA, Cost (USD)	5/9	Azure Neural, CosyVoice2, F5-TTS, Google Neural2, OpenAI tts-1
TTS	UTMOSv2, WER	3/9	Azure Neural, CosyVoice2, Google Neural2
TTS	UTMOSv2, Cost (USD)	1/9	CosyVoice2
TTS	WER, Cost (USD)	3/9	CosyVoice2, Google Neural2, OpenAI tts-1
CLONING	UTMOSv2, NISQA, WavLM, WER, Cost (USD)	7/8	CosyVoice2, ElevenLabs, F5-TTS, Fish-Speech S1, Fish-Speech S2 Pro, Resemble, Typecast
CLONING	UTMOSv2, WavLM, Cost (USD)	1/8	CosyVoice2
CLONING	UTMOSv2, WavLM, WER, Cost (USD)	6/8	CosyVoice2, ElevenLabs, Fish-Speech S1, Fish-Speech S2 Pro, Resemble, Typecast
CLONING	UTMOSv2, NISQA, WavLM, Cost (USD)	6/8	CosyVoice2, ElevenLabs, F5-TTS, Fish-Speech S1, Fish-Speech S2 Pro, Resemble
CLONING	UTMOSv2, WavLM, Скорость (с)	5/8	CosyVoice2, ElevenLabs, F5-TTS, Resemble, XTTSv2
CLONING	UTMOSv2, Cost (USD)	1/8	CosyVoice2
CLONING	WavLM, Cost (USD)	1/8	CosyVoice2

7.5 H2: согласованность метрик

H2.tts.naturalness. На системном уровне корреляция UTMOSv2 vs NISQA на TTS-задаче составляет $\rho = 0.500$ ($p = 0.170$, $N = 9$ провайдеров). Это ниже порога 0.7. Гипотеза H2.tts.naturalness **не подтверждена**.

H2.cloning.naturalness. На cloning-задаче $\rho = -0.190$ ($p = 0.651$). Гипотеза H2.cloning.naturalness **не подтверждена**.

Интерпретация. Несмотря на то, что обе метрики номинально измеряют «естественность речи», их системные ранги существенно расходятся. Можно предположить, что UTMOSv2 более чувствителен к артефактам нейронного синтеза (плавающие prosody-границы, неестественная просодия), тогда как NISQA — к классическим артефактам канала и кодека (ширина полосы, спектральные перекосы). Для коммерческих провайдеров с близким к идеальному каналом NISQA быстро упирается в потолок (5.0), что также вносит сжатие диапазона.

H2.cloning.similarity. На cloning-задаче WavLM vs ECAPA дают $\rho = 0.976$ ($p = < 0.001$, $N = 8$). Хотя обе метрики архитектурно различны, на системном уровне они почти идентично ранжируют провайдеров (см. Рис. 3). Поскольку нам требовалось

$\rho < 0.7$, гипотеза H2.cloning.similarity **не подтверждена**. Этот результат полезен: достаточно использовать любую одну из них.




Figure 3: Матрица Spearman-корреляций между метриками на уровне отдельных файлов (по 6680 строкам, попадающим в статистический анализ; в каждой паре учитываются только строки с непустыми значениями обеих метрик). Сильная положительная корреляция между WavLM- и ECAPA-similarity отражает то, что обе модели измеряют одно и то же; слабая связь UTMOSv2–NISQA подтверждает результат проверки H2.

7.6 H3: эквивалентность commercial и OSS групп

Гипотеза H3 проверяется отдельно для каждой комбинации (задача, метрика) с помощью двустороннего TOST-теста на провайдер-уровневых средних в группах commercial и open-source (формулировка и пороги δ — см. Раздел 6.3). Результаты по всем восьми (задача, метрика)-комбинациям сведены в Таблицу 7; распределения средних по группам визуализированы на Рис. 4.

Сводные результаты по задачам:

- **TTS, UTMOSv2.** $\bar{x}_C = 3.734$, $\bar{x}_{OS} = 3.580$ ($\Delta = +0.154$ при $\delta = 0.200$); TOST $p = 0.338$ — эквивалентность **не подтверждена**.

Table 7: Результаты теста НЗ по каждой (задача, метрика)-комбинации. Двусторонний TOST на провайдер-уровневых средних (commercial vs open-source): $H_0 : |\bar{x}_C - \bar{x}_{OS}| \geq \delta$. Колонки: $\bar{x}_C$ — среднее по commercial-провайдерам, $\bar{x}_{OS}$ — по open-source; Δ — наблюдаемая разность средних; δ — пре-регистрированный порог эквивалентности (см. Раздел 6.3). Эквивалентность считается подтверждённой (✓) при $p < 0.05$. Для метрик speaker similarity провайдеры без zero-shot эндпоинта (Azure, Google, OpenAI) исключены.

(Задача, Метрика)	$\bar{x}_C$	$\bar{x}_{OS}$	Δ	δ	p -value	Итог
TTS, UTMOSv2	3.734	3.580	+0.154	0.200	0.338	×
TTS, NISQA	4.928	4.553	+0.374	0.200	0.849	×
TTS, Whisper-WER	0.037	0.040	-0.003	0.050	< 0.001	✓
Cloning, UTMOSv2	3.436	3.401	+0.035	0.200	0.184	×
Cloning, NISQA	4.817	4.705	+0.113	0.200	0.160	×
Cloning, Whisper-WER	0.035	0.041	-0.006	0.050	< 0.001	✓
Cloning, WavLM-sim	0.942	0.957	-0.015	0.050	0.001	✓
Cloning, ECAPA-sim	0.665	0.732	-0.067	0.050	0.664	×

- **TTS, NISQA.** $\bar{x}_C = 4.928$, $\bar{x}_{OS} = 4.553$ ($\Delta = +0.374$ при $\delta = 0.200$); TOST $p = 0.849$ — эквивалентность **не подтверждена**.
- **TTS, Whisper-WER.** $\bar{x}_C = 0.037$, $\bar{x}_{OS} = 0.040$ ($\Delta = -0.003$ при $\delta = 0.050$); TOST $p = < 0.001$ — эквивалентность **подтверждена**.
- **Cloning, UTMOSv2.** $\bar{x}_C = 3.436$, $\bar{x}_{OS} = 3.401$ ($\Delta = +0.035$ при $\delta = 0.200$); TOST $p = 0.184$ — эквивалентность **не подтверждена**.
- **Cloning, NISQA.** $\bar{x}_C = 4.817$, $\bar{x}_{OS} = 4.705$ ($\Delta = +0.113$ при $\delta = 0.200$); TOST $p = 0.160$ — эквивалентность **не подтверждена**.
- **Cloning, Whisper-WER.** $\bar{x}_C = 0.035$, $\bar{x}_{OS} = 0.041$ ($\Delta = -0.006$ при $\delta = 0.050$); TOST $p = < 0.001$ — эквивалентность **подтверждена**.
- **Cloning, WavLM-sim.** $\bar{x}_C = 0.942$, $\bar{x}_{OS} = 0.957$ ($\Delta = -0.015$ при $\delta = 0.050$); TOST $p = 0.001$ — эквивалентность **подтверждена**.
- **Cloning, ECAPA-sim.** $\bar{x}_C = 0.665$, $\bar{x}_{OS} = 0.732$ ($\Delta = -0.067$ при $\delta = 0.050$); TOST $p = 0.664$ — эквивалентность **не подтверждена**.

По восьми проверкам результаты распадаются на три качественно различные группы. **Группа 1: эквивалентность подтверждена** — Whisper-WER в обеих задачах ($p < 0.001$) и WavLM-similarity в задаче клонирования ($p = 0.001$). На этих метриках наблюдаемая разница между группами лежит существенно ниже δ ($|\Delta| \leq 0.015$ против $\delta = 0.05$), что означает: в пределах методологически значимого порога коммерческие сервисы не дают пользователю преимущества по разборчивости и по схожести синтезированного голоса с опорным диктором. **Группа 2: эквивалентность не подтверждена, разница превышает δ** —

NISQA на TTS-задаче ($\Delta = +0.374 > \delta = 0.200$ в пользу коммерческих) и ESCAPA-similarity на cloning-задаче ($\Delta = -0.067 > \delta = 0.050$ в пользу open-source). Это две метрики, на которых группы действительно различаются больше методологического порога, причём направление различий противоположно: коммерческие провайдеры заметно лучше по *студийному* качеству звучания (NISQA исторически разрабатывался для оценки телефонной речи и реагирует на ширину полосы и спектральную чистоту), а open-source модели — по эмбедингу диктора по ESCAPA. **Группа 3: тест неопределённый** — UTMOSv2 в обеих задачах и NISQA в задаче клонирования. Здесь наблюдаемая разница меньше δ , но односторонние p -value не достигают 0.05, поэтому формально TOST не отвергает $H_{0,TOST}$; такая картина типична при недостаточной статистической мощности (всего 6 коммерческих и 5 open-source провайдеров в TTS-задаче и 3 vs 5 в cloning-задаче после исключения fake-cloning сервисов). Содержательно это означает: эффект, если он и есть, заведомо невелик, но имеющихся N провайдеров не хватает, чтобы уверенно объявить эквивалентность. Более глубокий разбор — в Разделе 8.4.




Figure 4: Сравнение распределений провайдер-уровневых средних между коммерческой (C) и open-source (OS) группой для трёх метрик качества (UTMOSv2, NISQA, Whisper-WER) и двух задач (TTS, voice cloning). Серая полоса вокруг общего среднего показывает интервал эквивалентности $\pm\delta$; провайдеры обеих групп, попадающие внутрь этой полосы, не превышают порога методологически значимого различия.

8 Обсуждение

8.1 Что значит «нет доминирующего TTS»?

H1.tts подтвердилась: 6 моделей из 9 на Парето-фронте в основной 4D-проекции (UTMOSv2, NISQA, WER, cost). Выбор TTS-системы зависит от приоритетов: при минимальной цене и максимальной скорости лидирует Google Neural2, при оптимизации естественности (UTMOSv2) — CosyVoice2 (open-source) или Azure Neural Speech, при сочетании скорости и натуральности — ElevenLabs (вне фронта, но близок). Ни одна модель не оптимальна по всем четырём осям одновременно. Это согласуется с интуитивным наблюдением, что коммерческие TTS API на текущем этапе развития конкурируют скорее в нишах (поддержка языков, голосов, prosody-разметка), чем в чистом качестве монопольной речи.

8.2 CosyVoice2 как универсально парето-оптимальная модель

В каноническом упрощённом представлении компромиссов voice cloning — трёхмерной проекции (UTMOSv2, WavLM-similarity, cost) — CosyVoice2 единолично доминирует над всеми остальными cloning-системами, включая коммерческие ElevenLabs IVC, Typecast SSFM-v30 и Resemble rapid. Это значит, что по UTMOSv2 и WavLM-similarity CosyVoice2 строго лучше всех коммерческих cloning-API в нашей выборке (по NISQA Resemble её обгоняет, 4.91 против 4.71), а её стоимость при этом нулевая.

При переходе к полной 5-мерной проекции (с добавлением NISQA и WER) на фронт возвращаются все три коммерческих провайдера: они оптимизированы под минимальный WER (3.4–3.6%) ценой меньшей WavLM-similarity (0.94 у ElevenLabs против 0.96 у CosyVoice2). Однако CosyVoice2 сохраняет позицию на фронте и в этой расширенной проекции. Более того, CosyVoice2 — единственная модель в нашем эксперименте, попадающая на Парето-фронт во всех изучаемых проекциях обеих задач (Таблица 6). Возможные объяснения такой универсальной оптимальности:

- CosyVoice2 обучена на крупном китайско-английском корпусе с использованием supervised semantic tokens; архитектура с LM-prior и Flow Matching-декодером оказалась эффективной как для естественности, так и для speaker similarity.
- Коммерческие zero-shot cloning-эндпоинты (ElevenLabs Instant, Typecast SSFM-v30, Resemble rapid) приоритизируют latency и стабильность вывода, а не максимальное качество в каждом отдельном файле; их более «тяжёлые» предложения требуют few-shot fine-tuning и в наш бенчмарк не вошли (см. ограничения, Раздел 9).
- Для ElevenLabs в нашем эксперименте использовались дефолтные значения параметров stability (0.5) и similarity (0.75); потенциальное улучшение при их

тонкой настройке остаётся открытым вопросом.

8.3 Метрики качества несут разный сигнал

Расхождение между UTMOSv2 и NISQA (Spearman $\rho = 0.500$ для TTS и $\rho = -0.190$ для cloning при пороге согласованности 0.7) показывает, что использовать одну метрику для финального вывода рискованно. На практике мы рекомендуем:

- Сообщать обе метрики и явно отделять «системную» оценку (mean by provider) от уровня отдельных высказываний.
- При близких значениях UTMOSv2 у нескольких моделей — использовать NISQA как tie-breaker.
- Для voice cloning достаточно одной из WavLM/ECAPA: они почти идеально согласованы.

8.4 Эквивалентность лагерей: что показывает TOST

НЗ проверяется тестом эквивалентности TOST на провайдер-уровневых групповых средних. Логика теста состоит в следующем: мы заранее фиксируем методологически значимый порог δ (для UTMOSv2/NISQA — 0.2 единицы шкалы 1–5, для WER и speaker similarity — 5 процентных пунктов и 0.05 соответственно) и явно проверяем, что наблюдаемая разность групповых средних не превышает δ . Тем самым НЗ формулируется и проверяется как утверждение об эквивалентности, а не как утверждение об отсутствии различий: подтверждение эквивалентности по конкретной (задача, метрика)-комбинации означает, что коммерческие провайдеры в среднем не дают пользователю преимущества выше порога δ по этой метрике; неподтверждение — что либо реальный разрыв (в любую сторону) превышает δ , либо мощности теста при $N = 5$ open-source и $N = 6$ коммерческих провайдеров не хватает для уверенного вывода (см. ограничения, Раздел 9). Конкретные численные вердикты по каждой (задача, метрика)-комбинации приведены в Таблице 7 (Раздел 6.3). Сводная таблица итогов по всем трём гипотезам — ниже.

Table 8: Сводная таблица проверки гипотез. Колонка «Итог» — ✓ = подтверждена, × = не подтверждена.

ID	Формулировка	Статистика	p-value	Итог
H1.tts	Pareto frontier (TTS) >1 провайдера	6/9 на Pareto	–	✓
H1.cloning	Pareto frontier (Cloning) >1 провайдера	7/8 на Pareto	–	✓
H2.tts.nat	UTMOSv2 и NISQA согласуются (TTS), $\rho \geq 0.7$	$\rho = 0.500$	0.170	×
H2.cloning.nat	UTMOSv2 и NISQA согласуются (Cloning), $\rho \geq 0.7$	$\rho = -0.190$	0.651	×
H2.cloning.sim	WavLM и ECAPA расходятся (Cloning), $\rho < 0.7$	$\rho = 0.976$	< 0.001	×
h3.tts.utmos	TOST: $ \bar{x}_C - \bar{x}_{OS} < \delta = 0.200$	$\bar{x}_C = 3.734, \bar{x}_{OS} = 3.580, \Delta = +0.154$	0.338	×
h3.tts.nisqa_mos	TOST: $ \bar{x}_C - \bar{x}_{OS} < \delta = 0.200$	$\bar{x}_C = 4.928, \bar{x}_{OS} = 4.553, \Delta = +0.374$	0.849	×
h3.tts.whisper_wer	TOST: $ \bar{x}_C - \bar{x}_{OS} < \delta = 0.050$	$\bar{x}_C = 0.037, \bar{x}_{OS} = 0.040, \Delta = -0.003$	< 0.001	✓
h3.cloning.utmos	TOST: $ \bar{x}_C - \bar{x}_{OS} < \delta = 0.200$	$\bar{x}_C = 3.436, \bar{x}_{OS} = 3.401, \Delta = +0.035$	0.184	×
h3.cloning.nisqa_mos	TOST: $ \bar{x}_C - \bar{x}_{OS} < \delta = 0.200$	$\bar{x}_C = 4.817, \bar{x}_{OS} = 4.705, \Delta = +0.113$	0.160	×
h3.cloning.whisper_wer	TOST: $ \bar{x}_C - \bar{x}_{OS} < \delta = 0.050$	$\bar{x}_C = 0.035, \bar{x}_{OS} = 0.041, \Delta = -0.006$	< 0.001	✓
h3.cloning.wavlm_sim	TOST: $ \bar{x}_C - \bar{x}_{OS} < \delta = 0.050$	$\bar{x}_C = 0.942, \bar{x}_{OS} = 0.957, \Delta = -0.015$	0.001	✓
h3.cloning.ecapa_sim	TOST: $ \bar{x}_C - \bar{x}_{OS} < \delta = 0.050$	$\bar{x}_C = 0.665, \bar{x}_{OS} = 0.732, \Delta = -0.067$	0.664	×

8.5 Стоимость как существенный фактор

Разница в стоимости между Google (\$16/1M) и Typecast (\$143/1M) — почти на порядок, при этом качество последнего не превосходит первого. Для типичного сценария применения с 1 миллиардом синтезированных символов в год экономия составит \$127K. Это делает выбор провайдера на основе одного только UTMOSv2 на практике рискованным.

8.6 Сильные и слабые стороны автоматических метрик

Сильные стороны: дешёвая итерация (5 сек/файл vs минуты на одного слушателя), полная воспроизводимость, отсутствие шума пула. Слабые: UTMOSv2 не различает «правильность интонации в контексте», WER не отражает супраконтекстных ошибок (например, неверное произношение редкого имени, но с правильным распознаванием Whisper). В будущем стоит дополнить пайплайн human-listening-тестом для подмножества аудио и сравнить ранги.

8.7 Сравнение с TTS Arena

TTS Arena (open Hugging Face лидерборд) использует только UTMOSv2 как метрику ранжирования, а также закрытый ELO-рейтинг от случайных слушателей. Сравнение наших средних значений UTMOSv2 с публичными значениями TTS Arena на момент написания работы:

- Наши Azure/OpenAI/ElevenLabs значения в районе 3.6–3.8 совпадают с TTS Arena в пределах ± 0.1 .
- CosyVoice2 у нас выше (3.95), чем в TTS Arena (~ 3.7) — возможно, из-за разницы в reference audio и подборки текстов.

Это подтверждает корректность наших измерений UTMOSv2 и косвенно — надёжность всего пайплайна.

9 Ограничения

1. **Английский язык, один корпус.** Все результаты получены на LibriTTS-R *test-clean*, что подразумевает чистую студийную речь и нейтральный домен (аудиокниги). Поведение моделей на эмоциональной речи, в шумных условиях, на других языках не обобщается.
2. **Дефолтные настройки провайдеров.** Каждый коммерческий API имеет десятки настроек (stability, similarity, speed); мы используем дефолты. Возможно, тонкая настройка изменит ранги.
3. **Только zero-shot voice cloning.** Few-shot режим с обучением на 30 минутах данных диктора у некоторых провайдеров (например, ElevenLabs Pro Voice Clone, Resemble custom voice) даёт качественно другие результаты, но требует существенной ручной работы и не включён в бенчмарк.
4. **Whisper-WER несимметричен.** Whisper сам несовершенен (WER $\sim 2\text{--}4\%$ на чистой английской речи), поэтому ASR-ошибки складываются с TTS-ошибками. Альтернатива — использовать несколько ASR-систем и брать минимум, но это утяжеляет pipeline.
5. **Выборка Resemble меньше.** 6 дикторов из 20 имеют слишком короткие reference, что снижает мощность тестов для Resemble на $\sim 30\%$.
6. **Отсутствие human evaluation.** Все наши выводы — через прокси-метрики. Расхождение UTMOSv2 и NISQA подсказывает, что вопрос «что есть качество» не закрыт.

10 Заключение

В работе представлен бенчмарк 11 коммерческих и open-source TTS- и voice-cloning-систем, сгенерировавших 6680 аудиозаписей, проанализированных с использованием пяти автоматических метрик. Ключевые наблюдения:

- В TTS-задаче не существует доминирующего провайдера; 6 моделей находятся на Парето-фронте «качество–стоимость».
- В voice-cloning-задаче полный 5D Парето-фронт (UTMOSv2, NISQA, WavLM-sim, WER, cost) содержит 7 из 8 моделей — доминирующего провайдера нет, но CosyVoice2 (open-source) единственная присутствует на фронте во всех изучаемых проекциях, демонстрируя самое сильное сочетание naturalness, speaker similarity и нулевой стоимости.
- Метрики naturalness UTMOSv2 и NISQA не достигают порога согласованности $\rho \geq 0.7$ ($\rho = 0.500$ для TTS, $\rho = -0.190$ для cloning), что подчёркивает важность отчётности по обеим.

- Метрики speaker similarity WavLM и ECAPA практически идентично ранжируют модели ($\rho = 0.976$); можно ограничиться одной.
- TOST-проверка эквивалентности коммерческой и open-source групп (Таблица 8) даёт три качественно разных исхода. Эквивалентность подтверждена ($p < 0.05$) по разборчивости Whisper-WER в обеих задачах и по WavLM-similarity в задаче клонирования — в этих осях коммерческие провайдеры не превосходят open-source более чем на δ . Эквивалентность не подтверждена и разница превышает δ только в двух случаях: NISQA на TTS (коммерческие выше на 0.37 против $\delta = 0.20$) и ECAPA-similarity на клонировании (open-source выше на 0.067 против $\delta = 0.05$). По UTMOSv2 и NISQA-cloning тест неопределённый: разница меньше δ , но мощности 5–6 провайдеров не хватает для отвержения $H_{0,\text{TOST}}$.

Все исходные коды, синтезированные аудио, метрики и таблицы публично доступны и позволяют расширять бенчмарк новыми провайдерами или метриками без пересинтеза существующих файлов.

References

- [1] H. Zen et al. “LibriTTS: A corpus derived from LibriSpeech for text-to-speech.” *Proc. Interspeech 2019*, pp. 1526–1530.
- [2] Y. Koizumi et al. “LibriTTS-R: A restored multi-speaker text-to-speech corpus.” *Proc. Interspeech 2023*.
- [3] T. Saeki, T. Saruwatari et al. “UTMOSv2: Improving MOS prediction with finetuned SSL embeddings.” *VoiceMOS Challenge 2024*.
- [4] G. Mittag, B. Naderi, A. Chehadi, S. Möller. “NISQA: A deep CNN-self-attention model for multidimensional speech quality prediction with crowdsourced datasets.” *Proc. Interspeech 2021*; arXiv:2104.09494.
- [5] S. Chen, C. Wang et al. “WavLM: Large-scale self-supervised pre-training for full stack speech processing.” *IEEE JSTSP*, 2022.
- [6] B. Desplanques, J. Thienpondt, K. Demuynck. “ECAPA-TDNN: Emphasized channel attention, propagation and aggregation in TDNN based speaker verification.” *Proc. Interspeech 2020*.
- [7] Hugging Face. “TTS Arena: Benchmarking text-to-speech models in the wild.” <https://huggingface.co/spaces/TTS-AGI/TTS-Arena>, 2024.

- [8] W.-C. Huang et al. “The VoiceMOS Challenge 2022: Predicting human MOS judgments of synthetic speech.” *Proc. Interspeech 2022*; arXiv:2203.11389. См. также VoiceMOS Challenge 2024, arXiv:2409.07001.
- [9] Z. Du et al. “CosyVoice 2: Scalable streaming speech synthesis with large language models.” arXiv:2412.10117, 2024.
- [10] E. Casanova et al. “XTTS: A massively multilingual zero-shot text-to-speech model.” *Proc. Interspeech 2024*; arXiv:2406.04904.
- [11] Y. Chen et al. “F5-TTS: A fairytaler that fakes fluent and faithful speech with flow matching.” arXiv:2410.06885, 2024.
- [12] G. Maniati et al. “SOMOS: The Samsung open MOS dataset for the evaluation of neural text-to-speech synthesis.” *Proc. Interspeech 2022*.
- [13] C.-H. Chiang, W.-P. Huang, H.-Y. Lee. “Why we should report the details in subjective evaluation of TTS more rigorously.” *Proc. Interspeech 2023*; arXiv:2306.02044.
- [14] E. Cooper, W.-C. Huang, T. Toda, J. Yamagishi. “Generalization ability of MOS prediction networks.” *Proc. ICASSP 2022*; arXiv:2110.02635.
- [15] “Position: Towards Responsible Evaluation for Text-to-Speech.” arXiv:2510.06927, 2025.
- [16] “Iterate to Differentiate: Enhancing discriminability and reliability in zero-shot TTS evaluation.” arXiv:2603.24430, 2026.
- [17] T. Saeki, D. Xin, W. Nakata, T. Koriyama, S. Takamichi, H. Saruwatari. “UTMOS: UTokyo-SaruLab system for VoiceMOS Challenge 2022.” *Proc. Interspeech 2022*; arXiv:2204.02152.
- [18] K. Baba et al. “The T05 system for VoiceMOS Challenge 2024: Transfer learning from deep image classifier to naturalness MOS prediction.” *Proc. SLT 2024*; arXiv:2409.09305.
- [19] G. Mittag, S. Möller. “Deep learning based assessment of synthetic speech naturalness.” *Proc. Interspeech 2020*.
- [20] C. Minixhofer, O. Klejch, P. Bell. “TTSDS — Text-to-Speech Distribution Score.” *Proc. SLT 2024*; arXiv:2407.12707.
- [21] C. Minixhofer et al. “TTSDS2: Resources and benchmark for evaluating human-quality text to speech systems.” arXiv:2506.19441, 2025.

- [22] A. Lemański, P. Junczyk et al. “ClonEval: An open voice cloning benchmark.” arXiv:2504.20581, 2025.
- [23] E. Cooper et al. “The VoiceMOS Challenge 2023: Zero-shot subjective speech quality prediction for multiple domains.” arXiv:2310.02640, 2023.
- [24] S. Wang, Y. Zhao et al. “Audio Turing Test: Benchmarking the human-likeness of LLM-based TTS systems.” arXiv:2505.11200, 2025.
- [25] Berlinski, Pomerleau et al. “Benchmarking the responsiveness of open-source TTS systems.” *Computers (MDPI)*, 2025.
- [26] R. R. Manku, Y. Tang, X. Shi, M. Li, A. Smola. “EmergentTTS-Eval: Evaluating TTS models on complex prosodic, expressiveness, and linguistic challenges using model-as-a-judge.” *NeurIPS 2025*; arXiv:2505.23009.
- [27] “The State of TTS: A case study with human fooling rates.” arXiv:2508.04179, 2025.
- [28] “An exploration of ECAPA-TDNN and x-vector speaker representations in zero-shot multi-speaker TTS.” arXiv:2506.20190, 2025.
- [29] “Automatic evaluation of speaker similarity.” Amazon; arXiv:2207.00344, 2022.
- [30] J. Xue, Y. Wang, J. Zhang, C. Liu, J. Tao. “ECAPA-TDNN for multi-speaker text-to-speech synthesis.” arXiv:2203.10473, 2022.
- [31] P. Anastassiou et al. “Seed-TTS: A family of high-quality versatile speech generation models.” arXiv:2406.02430, 2024. (Протокол Seed-TTS-eval: WER через Whisper-large-v3, SIM через WavLM-large.)
- [32] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, I. Sutskever. “Robust speech recognition via large-scale weak supervision.” *ICML 2023*; arXiv:2212.04356.
- [33] D. Lakens. “Equivalence tests: A practical primer for t -tests, correlations, and meta-analyses.” *Social Psychological and Personality Science*, 8(4), 2017.
- [34] D. Lakens, A. M. Scheel, P. M. Isager. “Equivalence testing for psychological research: A tutorial.” *Advances in Methods and Practices in Psychological Science*, 1(2), 2018.
- [35] J. Chevelu et al. “How to compare TTS systems: a new subjective evaluation methodology focused on differences.” *Proc. Interspeech 2015*.
- [36] Z. Du, C. Gao, Y. Wang et al. “CosyVoice 3: Towards in-the-wild speech generation via scaling-up and post-training.” arXiv:2505.17589, 2025.
- [37] “Qwen3-TTS Technical Report.” arXiv:2601.15621, 2026.

- [38] C. Wang et al. “Neural codec language models are zero-shot text to speech synthesizers (VALL-E).” arXiv:2301.02111, 2023.
- [39] S. Chen et al. “VALL-E 2: Neural codec language models are human parity zero-shot TTS synthesizers.” arXiv:2406.05370, 2024.
- [40] X. Tan et al. “NaturalSpeech: End-to-end text to speech synthesis with human-level quality.” *IEEE TPAMI*; arXiv:2205.04421.
- [41] K. Shen et al. “NaturalSpeech 2: Latent diffusion models are natural and zero-shot speech and singing synthesizers.” arXiv:2304.09116, 2023.
- [42] X. Tan, T. Qin, F. Soong, T.-Y. Liu. “A survey on neural speech synthesis.” arXiv:2106.15561, 2021.